

练习题目

第一阶段：数据预处理与特征工程（对应你所学的基础计算、分组计算、数据转换等）

1. 缺失值处理

- 查看数据集中各数值列的缺失值比例
- 分别使用**均值**、**中位数**、**分组填充（按城市 + 季节）** 填充缺失值，对比三种方式的差异
- 最终选择分组填充作为缺失值处理的最终方案，生成新列**平均气温_填充**、**降雨量_填充**

2. 异常值修正

- 对**平均气温_填充**、**PM2.5**列使用**95 分位数法**和**3 σ 原则**识别并修正异常值，生成**平均气温_清洗**、**PM2.5_清洗**列
- 可视化异常值（箱线图），验证修正效果

3. 基础统计与分组计算

- 计算所有数值列的均值、中位数、标准差、最大值、最小值（使用**describe()**和单独统计函数）
- 按**城市**分组，计算各城市的平均气温、降雨量、PM2.5 的均值和标准差
- 按**城市 + 季节**分组，计算各分组的湿度中位数，并将结果广播到原数据集（生成**城市季节湿度中位数**列）
- 统计各空气质量等级的数量（使用**crosstab**或**groupby+size**）

4. 特征工程（数值 + 分类）

- **数值特征衍生：**
 - 将**平均气温_清洗**离散化为「低温 (<0)、中温 (0~25)、高温 (>25)」，生成**气温等级**列
 - 计算各城市的年均温（按城市 + 年份分组），生成**城市年均温**列
 - 计算当前气温与城市年均温的差值，生成**气温偏差**列
- **分类特征处理：**
 - 对**季节**列进行**标签编码**（Label Encoding），生成**季节编码**列
 - 对**城市**、**天气类型**列进行**独热编码**（One-Hot Encoding）
 - 使用**map**函数将**空气质量**映射为数值：优→4，良→3，轻度污染→2，中度污染→1

5. 条件筛选与计算

- 筛选出 2024 年夏季平均气温 $> 30^{\circ}\text{C}$ 的城市数据
- 统计各城市重度污染（这里用中度污染替代）的天数占比
- 计算每个季节的降雨量总和，并排序

6. 排序与排名

- 按PM2.5_清洗降序排序，取前 10 条数据
- 按城市分组，取每组中降雨量最大的一条数据
- 对湿度列进行密集排名（dense），生成湿度排名列

第二阶段：数据可视化（折线图、柱状图、饼图、散点图）

要求：使用matplotlib或seaborn绘制，每个图需包含标题、坐标轴标签、图例（如需），并保存图片。

1. 折线图

- 绘制北京、上海、广州三个城市 2020-2024 年的年均温变化趋势（x 轴：年份，y 轴：年均温，多条折线）
- 绘制 2024 年全国平均 PM2.5 浓度随季节的变化趋势（x 轴：季节，y 轴：PM2.5 浓度）

2. 柱状图

- 绘制 2024 年各城市的平均降雨量对比（横向柱状图）
- 绘制各空气质量等级的数量分布（纵向柱状图）
- 绘制不同季节的气温等级分布（堆叠柱状图：x 轴季节，y 轴数量，不同颜色代表气温等级）

3. 饼图

- 绘制 2024 年全国天气类型的占比饼图（显示百分比）
- 绘制北京市空气质量等级的占比饼图（按年份划分，子图形式展示 5 年数据）

4. 散点图

- 绘制平均气温与湿度的散点图（x 轴：气温，y 轴：湿度，颜色区分季节）
- 绘制 PM2.5 与降雨量的散点图（x 轴：降雨量，y 轴：PM2.5，大小表示气温，颜色区分空气质量）
- 绘制气温偏差与 PM2.5 的散点图，并添加趋势线

第三阶段：聚类分析（使用 K-Means 算法）

1. 数据准备

- 选择聚类特征：平均气温_清洗、降雨量_填充、PM2.5_清洗、湿度（数值特征）
- 对特征进行**标准化**（使用`sklearn.preprocessing.StandardScaler`），消除量纲影响

2. K 值选择

- 使用**肘部法则**（绘制聚类损失随 K 值变化的折线图）确定最佳 K 值（K 从 1 到 10）
- （可选）使用**轮廓系数**验证最佳 K 值

3. K-Means 聚类

- 使用最佳 K 值进行 K-Means 聚类，将聚类结果作为新列聚类标签添加到原数据集
- 统计每个聚类的样本数量、各特征的均值

4. 聚类结果可视化

- 使用**散点图**展示聚类结果（选取两个特征作为 x、y 轴，颜色区分聚类标签）
- 使用**平行坐标图**或**热力图**分析各聚类的特征差异
- 结合分类特征（如城市、季节），分析每个聚类的特征分布（例如：聚类 1 主要是北方城市冬季数据，聚类 2 主要是南方城市夏季数据）

5. 聚类结果解读

- 总结每个聚类的特征特点（例如：聚类 0 为「高温、低 PM2.5、高湿度」的城市季节数据）
- 分析聚类结果的业务意义（例如：哪些城市季节的环境条件更优）

（注：文档部分内容可能由 AI 生成）